**Diplomatura en Ciencia de Datos y Análisis Avanzado**

**Entrega trabajo final integrador 2026**

# Dónde poner la lupa, un modelo de riesgo de informalidad laboral con la EPH

**26/10/2026**


Integrantes:

- Mirabella, Renzo
- Viera, Bernardita

# 1. Resumen ejecutivo

**Problema.** En el primer trimestre de 2026 la informalidad laboral alcanzó el 44,2 % de los ocupados, y para revertirla la Ley 27.802 creó dos herramientas, el PER (Promoción del Empleo Registrado), pensado para regularizar a trabajadores que ya están contratados, y el RIFL (Régimen de Incentivo a la Formalización Laboral), pensado para las nuevas contrataciones. Las dos funcionan a través de un empleador privado, y como la Secretaría de Trabajo y ARCA no pueden inspeccionar ni acompañar a todos, necesitan saber dónde poner la lupa.

**Solución.** Con los microdatos de la EPH construimos un modelo que estima el riesgo de informalidad y lo resume en segmentos de rama de actividad, tamaño del establecimiento y región, para lo cual comparamos cuatro algoritmos (regresión logística, árbol de decisión, Random Forest y XGBoost) contra una regla simple por rama y tamaño, con validación cruzada y una única evaluación final sobre un 20 % de datos reservado, de la que salió elegido el Random Forest. El resultado es siempre una lista de segmentos y nunca de personas ni de empresas.

**Resultado.** Sin focalizar, 43 de cada 100 trabajadores bajo la lupa son informales, mientras que en los segmentos que prioriza la regla son 75 y con el modelo 78, por lo que a nivel segmentos, que es donde el Estado decide, el modelo supera a la regla por solo 2,4 puntos y esa diferencia no es estadísticamente significativa, y por eso recomendamos usar la regla como herramienta operativa y el modelo como herramienta de diagnóstico. Además encontramos que el 54,6 % de los informales (cuentapropistas, casas particulares y sector público) queda fuera del alcance de la ley porque no tiene un empleador privado, y que si en lugar de ordenar a todos los ocupados se ordena solo a los asalariados privados, con el mismo esfuerzo se alcanza a 1,78 millones de informales formalizables en vez de 0,55 millones.

**Impacto y recomendación.** Proponemos concentrar las inspecciones y la difusión del PER antes del 28/11/2026 en los asalariados privados de los segmentos de mayor riesgo, empezando por los establecimientos de 6 a 40 personas de construcción y gastronomía, que son los que tienen más capacidad de formalizar, y acompañar a los establecimientos más chicos para que accedan a las mejores condiciones del PER en lugar de solo inspeccionarlos. También creemos necesario diseñar medidas propias para cuentapropistas y casas particulares, que suman el 47 % de los informales, y medir la gestión con un nuevo indicador, la cantidad de informales con empleador privado cada 100 trabajadores bajo la lupa.

# 2. Definición del problema y relevancia

En el primer trimestre de 2026, el 44,2 % de los ocupados de los aglomerados urbanos trabajaba en la informalidad, es decir casi 6 de los 13,5 millones de personas, sin aportes jubilatorios, obra

social ni las demás protecciones del empleo registrado. De esos informales, el 57 % son asalariados de empleadores privados (11,6 puntos de ellos en casas particulares), el 36 % son cuentapropistas, el 4,5 % asalariados del sector público y el 3 % patrones y trabajadores familiares, y esta composición termina siendo clave para saber hasta dónde pueden llegar las herramientas de la ley.

Para reducirla, la Ley 27.802 creó dos herramientas, por un lado el PER (Régimen de Promoción del Empleo Registrado, Decreto 409/2026 y RG ARCA 5862/2026), que permite a los empleadores regularizar relaciones laborales no registradas iniciadas hasta el 5/3/2026 con una condonación de entre el 70 % y el 90 % de la deuda según el tamaño de la empresa y cuyo plazo vence el 28/11/2026, y por otro lado el RIFL (Régimen de Incentivo a la Formalización Laboral, Decreto 315/2026), que reduce durante 48 meses las contribuciones patronales de las nuevas contrataciones de personas sin empleo registrado reciente que se registren entre el 1/5/2026 y el 30/4/2027.

Las dos herramientas funcionan a través de un empleador privado que decide regularizar o contratar, y como el Estado no puede formalizar trabajadores uno por uno ni inspeccionar a todos los empleadores, lo que sí puede hacer es concentrar inspecciones, controles y campañas en los sectores donde la informalidad es alta y donde estas herramientas pueden actuar. Por eso el proyecto busca responder dos preguntas para la Secretaría de Trabajo, Empleo y Seguridad Social y para ARCA, que son los organismos que aplican la ley, por un lado qué segmentos concentran la informalidad en los que el empleador puede formalizar, y por otro qué parte de los informales está en una situación a la que las herramientas actuales no llegan.

Decidimos que la unidad de decisión sea el segmento (rama de actividad × tamaño del establecimiento × región) y no la persona, ya que la EPH es anónima y además no hay capacidad logística para actuar caso por caso, por lo que los modelos se eligen según su rendimiento a nivel segmentos y el rendimiento a nivel personas se reporta solo como referencia.

Nuestro objetivo es construir un modelo de clasificación que estime el riesgo de informalidad de los ocupados y ordenar con él los segmentos, para concentrar inspecciones e incentivos en el 20 % del empleo de mayor riesgo con mejores resultados que los que la autoridad lograría sin un modelo.

Las metas que fijamos en la pre-entrega se miden sobre ese 20 % bajo la lupa, la primera es la precisión, o sea cuántos de cada 100 trabajadores bajo la lupa son informales, con una meta de al menos 85 contra 44 si no se focaliza, la segunda es superar por al menos 5 puntos de precisión a una regla simple por rama y tamaño, que representa lo que la autoridad podría hacer sin un

modelo, y la tercera es de equidad, que el recall de ningún grupo de sexo o región quede más de 10 puntos por debajo del promedio.

Planteamos tres hipótesis, la primera es que el tamaño del establecimiento y la rama de actividad son los predictores más fuertes de la informalidad, la segunda es que los atributos individuales como la edad, el sexo y el nivel educativo agregan capacidad predictiva, con más riesgo en los jóvenes y en quienes tienen menos educación, y la tercera es que una gran parte de la informalidad está en grupos a los que las herramientas actuales llegan poco, como los cuentapropistas que no tienen empleador, las casas particulares que quedan fuera del RIFL y los microestablecimientos que tienen poca capacidad contributiva.

Creemos que este análisis es importante porque los recursos de inspección son escasos y focalizarlos permite encontrar muchos más casos de informalidad que actuar al azar, sobre todo con una ventana del PER que se cierra el 28/11/2026, y porque también permite conocer los límites de estas herramientas y dimensionar qué parte de los informales queda por fuera, para poder pensar otras medidas.

## 3. Datos y Metodología

Usamos los microdatos de la base individual de la Encuesta Permanente de Hogares (EPH) del INDEC para el primer trimestre de 2026, que son datos públicos y anonimizados con cita obligatoria de la fuente, y tienen 43.739 personas y 234 variables sin registros duplicados. La población de análisis son los 19.560 ocupados con dato de formalidad, que representan a 13,5 millones de trabajadores de 32 aglomerados urbanos, por lo que quedan afuera los 13 ocupados sin ese dato y los 1.423 desocupados.

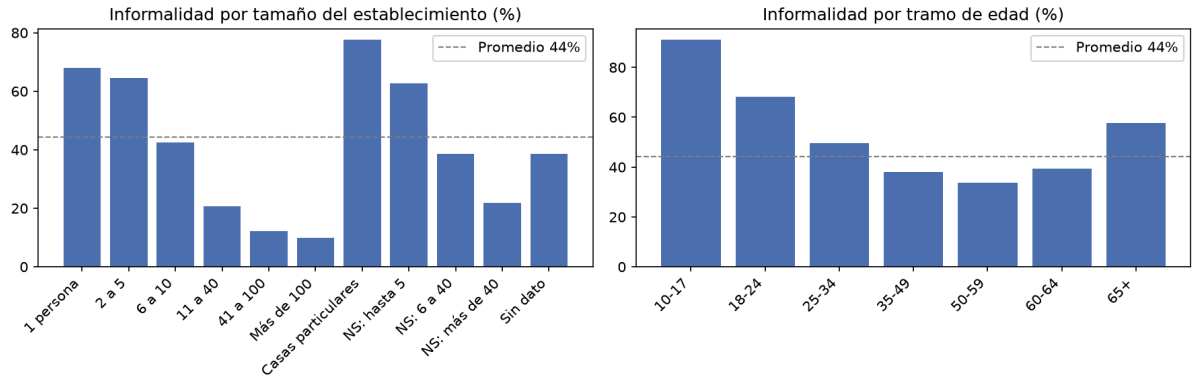
Como la EPH tiene un diseño muestral estratificado y en varias etapas, no todas las personas tienen la misma probabilidad de ser seleccionadas, por eso todas las tasas y métricas del trabajo se calculan ponderadas con PONDERA, el factor de expansión del INDEC que indica cuántas personas representa cada encuestado. Como control, la tasa de informalidad ponderada da 44,2 %, idéntica a la que publica el INDEC, mientras que sin ponderar daría 45,0 %, lo que confirma que replicamos la definición oficial y muestra el sesgo que aparece si se trata a la muestra como representativa por sí sola.

**Variables y calidad de los datos.** El target es EMPLEO, que el INDEC construye a partir de los aportes y la registración declarados, y el modelo usa una lista cerrada de 9 predictores agrupados en tres bloques, el del puesto de trabajo (rama de actividad, tamaño del establecimiento, categoría ocupacional, ámbito del establecimiento y calificación de la tarea), el de la persona (edad en tramos, sexo y nivel educativo) y el territorial (región), y además usamos PONDERA para las

métricas y CODUSU para armar la partición. La base no tiene celdas vacías sino que la falta de información aparece como códigos numéricos, que recodificamos uno por uno sin imputar, por ejemplo los trabajadores de casas particulares quedaron como una categoría propia de tamaño y a quienes no sabían el tamaño exacto los ubicamos en un rango aproximado con la pregunta de respaldo PP04C99, con lo que recuperamos 1.334 de 2.609 casos, además de reconstruir los códigos que perdían el cero inicial al leerse como números.

Excluimos las variables que forman parte de la propia definición de informalidad, como las vacaciones pagas, el aguinaldo, la obra social y el descuento jubilatorio en los asalariados, la registración del negocio en los independientes y el sector, porque con ellas el modelo hubiera "acertado" sin aprender nada útil, ya que el descuento jubilatorio solo clasifica bien al 100 % de los asalariados y la registración del negocio al 98 % de los independientes, mientras que nuestros 9 predictores por separado clasifican entre el 62 % y el 77 %. Tampoco usamos el ingreso, que además tiene un 19 % de no respuesta, ni las horas trabajadas, porque en parte son consecuencia de la informalidad y no sirven para decidir dónde inspeccionar.

**Análisis exploratorio.**




El análisis exploratorio mostró que el tamaño del establecimiento es el corte más fuerte, ya que la informalidad cae del 68 % en quienes trabajan solos al 10 % en los establecimientos de más de 100 personas, y que la rama también separa mucho, con 76 % en construcción y 77 % en casas particulares contra 11 % en administración pública y en finanzas, mientras que por categoría los cuentapropistas llegan al 65 % contra el 38 % de los asalariados. Entre los factores personales, la informalidad tiene forma de U con la edad (68 % entre 18 y 24 años, 34 % entre 50 y 59 y 58 % desde los 65), por eso la usamos en tramos, y baja con la educación desde el 73 % con primario incompleto hasta el 17 % con superior completo, y por región Cuyo, NEA y NOA superan el 52 % mientras que Patagonia está en el 27 %.

**Preparación de los datos.** Para la regla simple y para los segmentos usamos una versión gruesa del tamaño (hasta 5 personas, de 6 a 40, más de 40, casas particulares y sin dato), y definimos los

segmentos como rama × tamaño grueso × región, que es la unidad sobre la que evaluamos los modelos. También definimos la población alcanzable como los asalariados de empleadores privados sin contar casas particulares, que son el 48,8 % de los ocupados y los únicos que tienen un empleador al que una inspección o un incentivo puede llevar a formalizar.

**Metodología y validación.** Seguimos la metodología CRISP-DM, registrando cada decisión con su fecha y su motivo en un data log, y el notebook se ejecuta completo de punta a punta con semilla fija. Para validar hicimos una partición 80/20 estratificada por el target y agrupada por vivienda, para que los miembros de una misma vivienda no quedaran a la vez en entrenamiento y en test, y seleccionamos los modelos con validación cruzada de 5 particiones sobre el 80 % de desarrollo, con la misma agrupación y con una regla de selección fijada antes de correrlos. Las métricas las calculamos a mano en cada partición ponderando por PONDERA, porque las funciones estándar de scikit-learn no aplican los pesos en la validación cruzada.

## 4. Modelado y evaluación

Planteamos un problema de clasificación binaria en el que cada modelo estima la probabilidad de que un ocupado sea informal, pero esa probabilidad no la usamos para clasificar a cada persona sino para ordenar a los ocupados y poner bajo la lupa al 20 % del empleo de mayor riesgo, por eso las métricas principales, la precisión, el recall y el F1, se calculan sobre ese 20 % y ponderadas por PONDERA, mientras que el AUC y el PR-AUC miden la calidad del ordenamiento completo. Cada modelo se evalúa en dos niveles, a nivel personas con el riesgo individual de cada uno y a nivel segmentos reemplazando ese riesgo por el promedio de su segmento.

Comparamos contra el azar y contra una regla rama × tamaño, que asigna a cada celda su tasa de informalidad en entrenamiento y representa lo que la autoridad haría sin un modelo, una regresión logística como baseline, un árbol de decisión por ser interpretable, un Random Forest, XGBoost y una variante de XGBoost con el carácter ocupacional para cerrar la duda que había quedado de la pre-entrega, todos con configuraciones moderadas y fijas, ya que no hicimos búsqueda de hiperparámetros para no sobreajustar la selección a la validación cruzada.

El criterio de selección lo fijamos antes de correr los modelos, para no elegir condicionados por los resultados, y fue la precisión al 20 % a nivel segmentos promediada en las 5 particiones, considerando empatados a los modelos que quedaran a menos de un desvío estándar del mejor y desempatando por simplicidad en el orden logística, árbol, Random Forest, XGBoost y XGBoost con carácter.

**Resultados.**

| Modelo | Precisión segmentos, validación cruzada | Precisión personas, test | Precisión segmentos, test | AUC, test |
|---|---|---|---|---|
| Azar | 44,6 | 42,8 | 42,8 | |
| Regla rama × tamaño | 78,9 ± 1,7 | 75,3 | 75,3 | 0,807 |
| Regresión logística | 80,7 ± 1,8 | 85,6 | 73,9 | 0,862 |
| Árbol de decisión | 74,0 ± 2,4 | 67,2 | 68,2 | 0,790 |
| Random Forest | 82,0 ± 1,1 | 85,7 | 77,8 | 0,862 |
| XGBoost | 81,2 ± 2,5 | 87,9 | 74,2 | 0,870 |
| XGBoost + carácter | 81,0 ± 0,9 | 88,6 | 75,1 | 0,876 |

Precisión al 20 % ponderada por PONDERA, en la validación cruzada se muestra la media y el desvío entre las 5 particiones.

En la validación cruzada el Random Forest fue el mejor a nivel segmentos con 82,0 %, y como XGBoost (81,2 %) y XGBoost con carácter (81,0 %) quedaron empatados con él, el desempate por simplicidad lo eligió a él, mientras que la logística quedó apenas afuera con 80,7 % frente a un umbral de 80,9 %, y el árbol rindió incluso por debajo de la regla, porque con 6 niveles no alcanza a representar las combinaciones de rama y tamaño y necesitaría unos 12, con lo que deja de ser interpretable. El test lo usamos una sola vez, con la selección ya cerrada y con el Random Forest y la regla reentrenados sobre todo el 80 % de desarrollo, y el Random Forest siguió siendo el mejor a nivel segmentos, así que la selección se sostiene, y aunque XGBoost tiene mejor AUC porque ordena mejor a las personas, esa ventaja no se traslada a los segmentos, que es donde se toma la decisión.

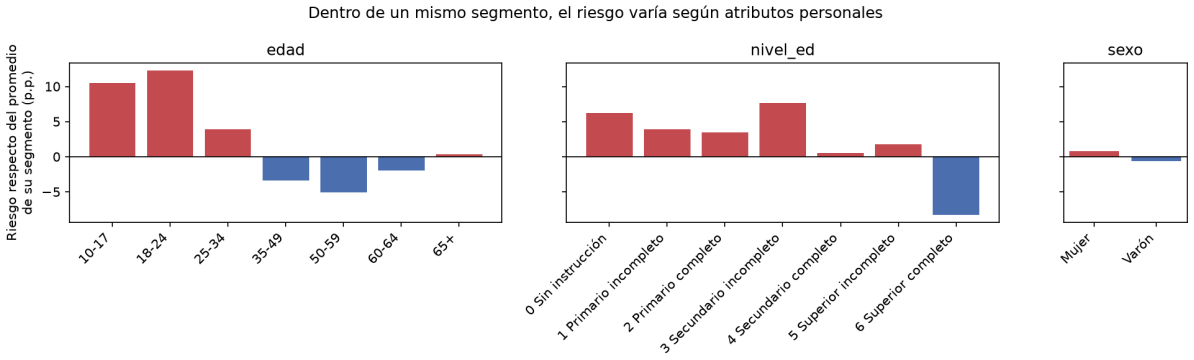
Random Forest sobre la regla.

| Nivel | Ventaja | IC 95% | Cumple meta +5 |
|---|---|---|---|
| Personas | +10,7 | +6,2 a +15,7 | si |
| Segmentos (criterio) | +2,4 | -1,5 a +6,0 | no |
| Segmentos, solo asalariados privados | +0,1 | -6,3 a +5,8 | no |

La meta de superar a la regla por 5 puntos se cumple al ordenar personas, porque el modelo usa la edad, la educación y el sexo de cada encuestado, pero a nivel segmentos, que es el criterio que fijamos siguiendo la devolución de la pre-entrega, la ventaja es de 2,4 puntos y no es estadísticamente significativa, por lo que aunque el Random Forest es el mejor modelo no conviene usarlo en lugar de la regla, y recomendamos la regla como herramienta para decidir dónde poner la lupa y el modelo como herramienta de diagnóstico.

## 5. Interpretación del modelo

Para entender de dónde viene la ventaja del modelo hicimos ablaciones, que consisten en reentrenar el Random Forest sacando un bloque de variables por vez y medir cuánto cae la precisión, y el detalle de cada variante está en el Anexo C.

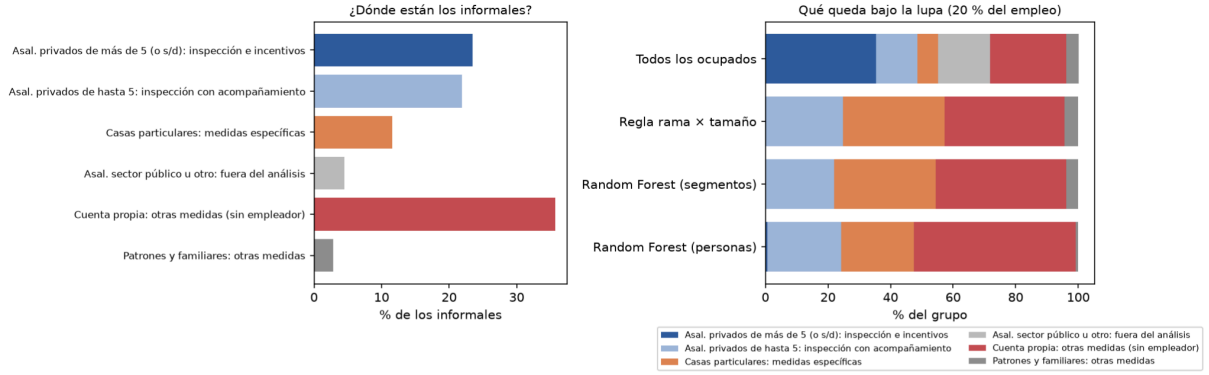



Sacar la rama y el tamaño produce la mayor caída en los dos niveles, 5,7 puntos a nivel personas y 6,6 a nivel segmentos, lo que respalda la primera hipótesis, mientras que sacar la edad, el sexo y la educación cuesta 2,9 puntos a nivel personas pero apenas 0,5 a nivel segmentos, y el sexo por sí solo casi no aporta, así que la segunda hipótesis se respalda solo en parte, porque los atributos personales ayudan a ordenar personas pero casi nada a elegir sectores. Lo que más nos llamó la atención fue que la región, que casi no pesa a nivel personas, cuesta 1,7 puntos a nivel segmentos y la regla no la usa, y que un modelo con solo rama y tamaño pero en tramos más finos que los de la regla ya recupera la mitad de la ventaja, por lo que el modelo sirvió sobre todo para mostrar lo que le falta a la regla, que es la región y los tramos finos de tamaño.

## 6. Impacto en el negocio, riesgos y ética

El KPI de la pre-entrega se cumple, ya que de cada 100 trabajadores en los segmentos priorizados entre 75 y 78 son informales, pero al mirar quiénes son encontramos un problema, porque el PER y el RIFL actúan a través de un empleador privado y el 54,6 % de los informales está fuera del alcance de ese mecanismo. Si se prioriza sobre todos los ocupados, la lupa se llena de

cuentapropistas y casas particulares y solo 20 de cada 100 trabajadores bajo la lupa son informales que estas herramientas pueden formalizar, lo mismo que eligiendo al azar, o sea que el KPI premiaba encontrar informales cuando el objetivo real era encontrar informales alcanzables por los instrumentos de la ley.




Por eso redefinimos dos cosas, la población que se ordena, que pasó a ser solo los asalariados de empleadores privados, y la métrica de negocio, que pasó a ser la cantidad de informales con empleador privado cada 100 trabajadores bajo la lupa.

| Dónde se pone la lupa | Informales formalizables cada 100 | Trabajadores bajo la lupa por cada uno | Informales formalizables alcanzados |
|---|---|---|---|
| Al azar, todos los ocupados | 20,1 | 5,0 | 0,54 millones |
| Regla, todos los ocupados | 20,5 | 4,9 | 0,55 millones |
| Regla, solo asalariados privados | 66,2 | 1,5 | 1,78 millones |

Datos de test expandidos a la población PONDERA.

Con el mismo esfuerzo se alcanzan 3,2 veces más casos formalizables, de 0,55 a 1,78 millones, o visto al revés, para llegar a los mismos 0,55 millones alcanzaría con poner bajo la lupa a 0,8 millones de asalariados privados en lugar de 2,7 millones de ocupados.

La lista de segmentos, la regla y la auditoría de equidad se regeneran con cada nueva EPH trimestral ejecutando el notebook, que tarda unos 3 minutos, sin necesidad de cambiar el código, lo que permite ir actualizando la priorización trimestre a trimestre.

| Segmentos | Informales | Tasa de informalidad | Estrategia |
|---|---|---|---|

| | | | |
|---|---|---|---|
| Comercio, hasta 5 personas | 414 | 71% | Inspección con acompañamiento |
| Construcción, hasta 5 personas | 288 | 94% | Inspección con acompañamiento |
| Industria, hasta 5 personas | 152 | 75% | Inspección con acompañamiento |
| Gastronomía, hasta 5 personas | 143 | 78% | Inspección con acompañamiento |
| Gastronomía, 6 a 40 personas | 139 | 55% | Inspección y PER |
| Construcción, 6 a 40 personas | 93 | 60% | Inspección y PER |
| Transporte, hasta 5 personas | 65 | 78% | Inspección con acompañamiento |

A partir de esta lista proponemos dos estrategias según el tamaño del establecimiento, en los de 6 a 40 personas inspección y PER, ya que tienen más capacidad de formalizar y la inspección puede hacerse con ese objetivo, y en los de hasta 5 personas inspección con acompañamiento, porque el PER les ofrece las mejores condiciones pero para acceder necesitan estar registrados como micro o pequeña empresa ante ARCA y tener el certificado MiPyME. Para los cuentapropistas y las casas particulares hacen falta otras herramientas, como el monotributo o el régimen de casas particulares, y el ranking sobre todos los ocupados sirve para dimensionarlos y tenerlos en cuenta en medidas futuras.

Entre los riesgos reconocemos que inspeccionar establecimientos muy chicos puede terminar en cierres o despidos, por eso recomendamos el acompañamiento, y que en los segmentos de establecimientos más grandes elegir qué empresa inspeccionar dentro del segmento requiere información administrativa adicional. También hay un riesgo de sesgo regional, ya que la regla subestima la informalidad en Cuyo, NEA y NOA, y aunque en la auditoría por grupos todos cumplen la meta de equidad, con Cuyo como el más alejado a 6,3 puntos por debajo del promedio (Anexo D), creemos que las inspecciones deberían repartirse de manera equitativa entre regiones. En cuanto a la privacidad, el resultado es siempre una lista de segmentos y la regla no usa atributos sensibles, por lo que en ningún momento se identifican personas.

## 7. Conclusiones y recomendaciones

Las metas de rendimiento se cumplen al ordenar personas, que es un nivel que el Estado no puede usar, y no al ordenar segmentos, que es donde decide, y además estaban definidas sobre todos los ocupados, cuando el análisis mostró que ese no era el lugar para medir el éxito, mientras que la meta de equidad sí se cumple. En cuanto a las hipótesis, la primera se respalda y la segunda solo en parte, como vimos en las ablaciones, y la tercera también se respalda, porque los cuentapropistas (35,7 % de los informales) y las casas particulares (11,6 %) suman el 47 %, y si se agregan los asalariados de microestablecimientos, que son otro 21,9 %, casi 7 de cada 10 informales están en grupos a los que las herramientas de la ley llegan poco o no llegan.

Concluimos que conviene poner la lupa entre los asalariados de empleadores privados, en los segmentos de construcción, gastronomía, comercio, industria y transporte de hasta 40 personas, y que para elegirlos alcanza con una regla simple por rama y tamaño, ya que lo que más cambia el resultado no es el algoritmo sino la población que se ordena, mientras que el Random Forest sirvió como diagnóstico para mostrar que a la regla le faltan la región y los tramos finos de tamaño.

Por todo esto recomendamos priorizar los segmentos con la regla rama × tamaño solo entre los asalariados de empleadores privados, concentrar antes del 28/11/2026 las inspecciones y la difusión del PER en los establecimientos de 6 a 40 personas de construcción y gastronomía, y en los microestablecimientos combinar la inspección con ayuda para registrarse como micro o pequeña empresa y obtener el certificado MiPyME, que les da acceso a las mejores condiciones del PER. También recomendamos diseñar medidas propias para cuentapropistas y casas particulares, por ejemplo a través del monotributo y del régimen de casas particulares, y medir la gestión con el nuevo indicador de informales con empleador privado cada 100 trabajadores bajo la lupa. Como próximos pasos proponemos incorporar a la regla la región y los tramos finos de tamaño y validarla con la EPH del próximo trimestre, regenerar la lista de segmentos y la auditoría con cada nueva EPH, y cruzar los segmentos priorizados con los registros de altas de ARCA para ver si la formalización efectivamente crece donde se puso la lupa.

Anexo A. Trazabilidad con la consigna y la pre-entrega

| **Peso** | **Criterio** | **Dónde está en el informe** |
|---|---|---|
| 20 % | Problema y alineación con el negocio | Sección 2, informalidad de 44,2 % (6 millones), PER y RIFL con su vencimiento, dos preguntas para la Secretaría de Trabajo y ARCA, unidad de decisión (segmentos), metas fijadas en la pre-entrega e hipótesis |
| 20 % | Datos, metodología y justificación técnica | Sección 3, validación contra INDEC (44,2 %), códigos especiales recodificados sin imputar, exclusión de variables por fuga con cifras, CRISP-DM, partición agrupada por vivienda y data log |
| 15 % | Selección y defensa del modelo | Sección 4, regla simple y seis modelos, criterio de selección fijado antes de correrlos, validación cruzada de 5 particiones, test usado una sola vez, y la distinción entre el mejor modelo y la herramienta recomendada |
| 15 % | Calidad de las métricas | Sección 4, precisión, recall y F1 al 20 %, AUC y PR-AUC, ponderadas por PONDERA, |

| Peso | Criterio | Dónde está en el informe |
|---|---|---|
| | | en dos niveles (personas y segmentos), con IC 95 % por bootstrap de viviendas, y los deciles en el Anexo B |
| 15 % | Interpretación y cuantificación de valor | Secciones 5 y 6, ablaciones (H1 y H2, Anexo C), redefinición del KPI, 3,2 veces más casos formalizables con el mismo esfuerzo, lista de segmentos y estrategias según tamaño |
| 5 % | Ética y privacidad | Sección 6, riesgos y mitigaciones, resultado en segmentos y no en personas y regla sin atributos sensibles, con la auditoría por grupos en el Anexo D |
| 10 % | Impacto y claridad | Resumen ejecutivo sin lenguaje técnico, tres figuras y recomendaciones ordenadas por prioridad en la sección 7 |

| **Comprometido** | **Estado en la entrega final** |
|---|---|
| Precisión @ 20 % de al menos 85 (KPI principal) | Evaluada en dos niveles: 85,7 a nivel personas (cumple) y 77,8 a nivel segmentos (no cumple) |
| Ventaja de al menos +5 puntos sobre la regla rama × tamaño | +10,7 a nivel personas (cumple); +2,4 a nivel segmentos, no significativa (IC 95 %: −1,5 a +6,0) |
| Ningún grupo de sexo o región más de 10 puntos por debajo del recall promedio | Cumple: el más alejado es Cuyo, con −6,3 (Anexo D) |
| Cobertura de los informales (KPI secundario) | Reportada como recall @ 20 % |
| Partición 80/20 estratificada y agrupada por hogar; validación cruzada de 5 particiones; test usado una sola vez; semilla fija | Ejecutado (SEED = 42) |
| Baseline logístico; árbol, Random Forest y gradient boosting | Ejecutado, con XGBoost como gradient boosting |
| Exclusión de variables por fuga (PP07G, PP07H, PP07I, SECTOR) | Aplicada y ampliada a PP07L y a PP05I a PP05K (registración del negocio de los independientes) |
| Pendiente: incorporar el carácter ocupacional | Cerrado: probado con XGBoost, no mejora ningún indicador; descartado |
| Pendiente: entrenamiento ponderado o no ponderado | Cerrado: la logística ponderada da 86,6 % contra 86,3 %; se mantiene sin ponderar |
| Hipótesis H1 a H3 | Evaluadas: H1 y H3 respaldadas, H2 en parte (Secciones 5 y 7) |

| Comprometido | Estado en la entrega final |
|---|---|
| Devolución del tutor: evaluar a nivel de segmentos | Es el criterio de selección de modelos; el nivel personas se reporta como referencia |
| Cambio respecto de la pre-entrega | Se agregó la métrica de negocio "informales con empleador privado cada 100 bajo la lupa" y el ranking se hace entre los asalariados privados (Sección 6) |

Anexo B. Lift por deciles (Random Forest, test estable)

Los ocupados del test se ordenan por el riesgo de su segmento y se dividen en 10 grupos de igual peso poblacional. El lift es la tasa del decil dividida por la tasa promedio (42,8 % en todos los ocupados; 40,6 % en asalariados privados).

| Decil | Todos: tasa de informalidad | Todos: lift | Todos: recall acumulado | Asal. privados: tasa de informalidad | Asal. privados: lift | Asal. privados: recall acumulado |
|---|---|---|---|---|---|---|
| 1 | 83,5 % | 1,95 | 19,5 % | 74,9 % | 1,85 | 18,5 % |
| 2 | 72,2 % | 1,69 | 36,4 % | 74,6 % | 1,84 | 36,9 % |
| 3 | 66,5 % | 1,56 | 51,9 % | 73,5 % | 1,81 | 55,0 % |
| 4 | 64,4 % | 1,51 | 67,0 % | 48,3 % | 1,19 | 66,9 % |
| 5 | 56,0 % | 1,31 | 80,1 % | 32,4 % | 0,80 | 74,9 % |
| 6 | 30,4 % | 0,71 | 87,2 % | 32,7 % | 0,81 | 82,9 % |
| 7 | 26,2 % | 0,61 | 93,3 % | 32,5 % | 0,80 | 90,9 % |
| 8 | 14,1 % | 0,33 | 96,6 % | 13,4 % | 0,33 | 94,2 % |

| Decil | Todos: tasa de informalidad | Todos: lift | Todos: recall acumulado | Asal. privados: tasa de informalidad | Asal. privados: lift | Asal. privados: recall acumulado |
|---|---|---|---|---|---|---|
| 9 | 9,3 % | 0,22 | 98,8 % | 12,2 % | 0,30 | 97,2 % |
| 10 | 5,2 % | 0,12 | 100,0 % | 11,2 % | 0,28 | 100,0 % |

- **Sobre todos los ocupados**, el primer decil tiene 83 % de informalidad, casi el doble del promedio, y la mitad de mayor riesgo concentra el 80 % de los informales.
- **Dentro de los asalariados privados**, los tres primeros deciles tienen alrededor de 74 % y después la tasa cae de golpe. Son, en su mayoría, asalariados de microestablecimientos: el ranking los agrupa en un bloque de riesgo casi uniforme.

## Anexo C. Modelo global vs. modelos por segmento

Se reentrenó el Random Forest sacando un bloque de variables por vez, con las mismas 5 particiones. La tabla muestra cuánto cae la precisión @ 20 % respecto del modelo completo (media ± desvío entre particiones; positivo = el bloque aportaba). PR-AUC del modelo completo: 0,820.

| Variante | Caída a nivel personas (p.p.) | Caída a nivel segmentos (p.p.) | PR-AUC (personas) | Qué contrasta |
|---|---|---|---|---|
| Sin rama ni tamaño | 5,7 ± 0,7 | 6,6 ± 3,6 | 0,755 | H1 |
| Sin edad, sexo ni educación | 2,9 ± 1,7 | 0,5 ± 1,1 | 0,794 | H2 |
| Sin sexo | 0,8 ± 0,8 | −0,2 ± 0,5 | 0,817 | H2, solo sexo |

| **Variante** | **Caída a nivel personas (p.p.)** | **Caída a nivel segmentos (p.p.)** | **PR-AUC (personas)** | **Qué contrasta** |
|---|---|---|---|---|
| Sin calificación de la tarea | 0,5 ± 1,4 | 0,7 ± 1,1 | 0,815 | Contraste |
| Sin categoría ni ámbito | 0,0 ± 0,5 | −0,1 ± 0,6 | 0,817 | Contraste |
| Sin región | 0,2 ± 0,6 | 1,7 ± 1,5 | 0,816 | Contraste |
| Solo rama y tamaño | 6,7 ± 2,1 | 1,6 ± 1,1 | 0,753 | Misma información que la regla, en tramos finos |
| Regla rama × tamaño (referencia) | 8,6 ± 1,0 | 3,1 ± 1,3 | — | Distancia entre la regla y el modelo |

- Rama y tamaño son el bloque que más aporta en los dos niveles (H1).
- Edad, sexo y educación aportan a nivel personas pero casi nada a nivel segmentos (H2, en parte).
- La región solo importa a nivel segmentos, y la regla no la usa: es una de las dos mejoras de la regla mejorada.
- "Solo rama y tamaño" queda a 1,6 puntos del modelo completo a nivel segmentos, contra 3,1 de la regla: los tramos finos de tamaño recuperan la mitad de la ventaja.

## Anexo D. Auditoría por grupos

Se audita la herramienta recomendada: la regla rama × tamaño aplicada a los asalariados privados, con el mismo esfuerzo que el 20 % del empleo total (2,7 millones de trabajadores bajo la lupa). Recall promedio: 65,8 %.

| Atributo | Grupo | Casos | Tasa real | Riesgo estimado: regla | Riesgo estimado: Random Forest | % del grupo bajo la lupa | Recall del grupo | Recall − promedio (p.p.) |
|---|---|---|---|---|---|---|---|---|
| Sexo | Mujer | 634 | 41,7 % | 39,5 % | 42,7 % | 38,4 % | 61,7 % | −4,1 |
| Sexo | Varón | 1.077 | 39,9 % | 41,6 % | 41,7 % | 41,5 % | 68,4 % | +2,6 |
| Región | Cuyo | 163 | 51,0 % | 40,8 % | 47,7 % | 36,9 % | 59,5 % | −6,3 |
| Región | GBA | 365 | 38,4 % | 39,7 % | 41,2 % | 38,4 % | 64,1 % | −1,7 |
| Región | NEA | 143 | 60,0 % | 49,6 % | 53,3 % | 62,5 % | 74,7 % | +8,8 |
| Región | NOA | 320 | 56,1 % | 46,7 % | 50,5 % | 50,8 % | 77,4 % | +11,6 |
| Región | Pampeana | 539 | 38,0 % | 42,1 % | 40,5 % | 41,3 % | 65,5 % | −0,3 |
| Región | Patagonia | 181 | 25,0 % | 32,5 % | 29,6 % | 29,5 % | 61,5 % | −4,3 |

- **Cobertura:** todos los grupos cumplen el criterio de la pre-entrega (ninguno más de 10 puntos por debajo). El más alejado es Cuyo, con -6,3.
- **Calibración:** la regla subestima la informalidad en Cuyo (10,2 puntos), NEA (10,4) y NOA (9,4), y la sobreestima en Patagonia (7,5). El Random Forest, que usa la región, se acerca más a la tasa real en todas las regiones salvo GBA. Es el motivo para incorporarla a la regla mejorada y el punto abierto sobre el criterio de equidad.
- Con el test, cada región tiene entre 143 y 539 casos, las diferencias de pocos puntos no son concluyentes.

## Anexo E. Reproducibilidad y fuentes

Repositorio: https://github.com/RenzoMirabella/integrador

Como reproducirlo: descargar `usu_individual_T126.xlsx` del sitio de INDEC, copiarlo en `data/`, instalar las dependencias y ejecutar el notebook completo. Toda la aleatoriedad se fija con `SEED = 42`. La primera ejecución tarda unos 3 minutos; para una nueva EPH trimestral alcanza con cambiar el nombre del archivo de datos.

Datos: INDEC, Encuesta Permanente de Hogares, microdatos de la base individual, primer trimestre de 2026. Datos públicos y anonimizados. https://www.indec.gob.ar/indec/web/Institucional-Indec-BasesDeDatos

Normativas utilizadas: - Ley 27.802 de Modernización Laboral.

- Decreto 315/2026: Régimen de Incentivo a la Formalización Laboral (RIFL).

- Decreto 409/2026: Régimen de Promoción del Empleo Registrado (PER).

- Resolución General ARCA 5862/2026: reglamentación del PER.